



Université Alioune Diop
L'Excellence est ma constance, l'Éthique ma vertu !

Master - Data Science et Génie Logiciel

SentimentAI

Analyse de sentiment par apprentissage automatique NLP

Comparaison de trois approches sur le dataset IMDB

Auteur : Papa Malick NDIAYE

1. Introduction

L'analyse de sentiment consiste à déterminer automatiquement si un texte exprime une opinion positive ou négative. C'est une tâche classique du traitement automatique du langage, utilisée par exemple pour suivre l'avis des clients sur un produit ou l'accueil réservé à un film.

Ce projet compare trois façons de résoudre ce problème, de la plus simple à la plus moderne, sur un même jeu de données. L'objectif n'est pas seulement d'obtenir le meilleur score, mais de comprendre ce que chaque approche apporte et ce qu'elle coûte.

Le jeu de données

Nous utilisons IMDB, un ensemble de 50 000 critiques de films en anglais, réparties en deux moitiés égales : 25 000 pour l'entraînement et 25 000 pour le test. Chaque critique est étiquetée positive ou négative, et les deux classes sont parfaitement équilibrées. Cet équilibre est important : il évite qu'un modèle obtienne un bon score en répondant toujours la même chose.

2. Les trois approches comparées

Préparer le texte : TF-IDF

Un ordinateur ne comprend pas les mots, il faut donc les transformer en nombres. La méthode TF-IDF donne à chaque mot un poids : élevé s'il est fréquent dans une critique donnée mais rare dans l'ensemble des critiques. Autrement dit, elle met en valeur les mots qui distinguent un texte des autres. Les mots très courants comme « the » ou « and » sont retirés au préalable, car ils n'apportent aucune information sur le sentiment.

Nous conservons aussi les paires de mots consécutifs. Cela permet de capturer des expressions comme « not good », dont le sens se perd si l'on regarde les mots isolément.

Approche 1 : régression logistique

Le modèle le plus simple des trois. À partir des poids TF-IDF, il apprend quels mots penchent vers le positif et lesquels vers le négatif, puis combine ces indices pour trancher. Son grand avantage est la transparence : on peut lire directement quels mots ont pesé dans la décision. Il s'entraîne en quelques minutes.

Approche 2 : forêts aléatoires

Cette méthode construit deux cents arbres de décision, chacun apprenant sur une partie différente des données, puis fait voter l'ensemble. L'idée est que les erreurs individuelles se compensent. Elle capture des combinaisons de mots plus complexes, mais reste plus lourde et moins lisible.

Approche 3 : DistilBERT

DistilBERT est un réseau de neurones déjà pré-entraîné sur d'énormes quantités de texte anglais. Il connaît donc la langue avant même de voir nos critiques. Contrairement aux deux

méthodes précédentes, il ne traite pas les mots isolément mais tient compte de leur contexte : il peut comprendre que dans « je ne pensais pas aimer ce film, mais... », la suite renverse le sens.

Nous l'avons spécialisé sur nos données par une phase de fine-tuning, c'est-à-dire un réentraînement léger à partir de ses connaissances existantes.

3. Résultats

Chaque modèle est jugé sur quatre indicateurs. La précision globale indique la proportion de bonnes réponses. Le F1-score équilibre deux risques : passer à côté de critiques positives, ou en déclarer à tort. L'AUC mesure la capacité du modèle à bien classer les critiques par ordre de confiance, indépendamment du seuil choisi. Plus ces valeurs sont proches de 1, meilleur est le modèle.

Modèle	Précision globale	F1-score	AUC
Régression logistique	89.22 %	89.22 %	0.959
DistilBERT	87.50 %	87.49 %	0.948
Forêts aléatoires	85.89 %	85.89 %	0.937

Les modèles classiques sont évalués sur les 25 000 critiques de test. DistilBERT l'est sur 2 000 critiques tirées aléatoirement, l'inférence sur l'ensemble complet étant trop lente sans carte graphique.




Figure 1 : comparaison des trois modèles.

Lecture des courbes ROC

La courbe ROC montre le compromis entre bien reconnaître les critiques positives et éviter les fausses alertes. Plus la courbe monte vite vers le coin supérieur gauche, meilleur est le modèle. La diagonale représente un modèle qui répondrait au hasard.




Figure 2 : courbe ROC de la régression logistique (AUC = 0,959).




Figure 3 : courbe ROC de DistilBERT (AUC = 0,948).

4. Analyse : un résultat contre-intuitif

Le résultat le plus intéressant de ce projet est inattendu : la régression logistique (89.2 %) devance DistilBERT (87.5 %), alors que ce dernier est de loin le modèle le plus sophistiqué. Ce constat mérite d'être expliqué plutôt que masqué.

L'explication

La comparaison n'est pas équitable en termes de moyens. La régression logistique a été entraînée sur la totalité des 25 000 critiques disponibles. DistilBERT, lui, n'a vu que 2 000 critiques, car son entraînement demande une puissance de calcul dont nous ne disposons pas : sans carte graphique, un entraînement complet aurait demandé plusieurs heures.

Nous comparons donc un modèle simple bien nourri à un modèle puissant sous-alimenté. Un réseau de neurones a besoin de beaucoup d'exemples pour exprimer son potentiel ; privé de données, il n'exploite qu'une fraction de ses capacités.

Ce que cela nous apprend

Cette observation constitue un enseignement utile plutôt qu'un échec. Elle rappelle qu'un modèle plus complexe n'est pas automatiquement meilleur : sa supériorité dépend des moyens qu'on peut lui consacrer. À budget limité, en données comme en calcul, une méthode classique bien réglée reste très compétitive.

C'est un critère concret de choix technique. La régression logistique s'entraîne en quelques minutes, occupe 240 kilo-octets et répond instantanément. DistilBERT pèse 268 mégaoctets et exige une infrastructure bien plus conséquente. Pour un gain de performance qui, ici, n'est pas au rendez-vous, le surcoût n'est pas justifié.

Signalons toutefois la limite de cette conclusion : elle vaut pour nos conditions d'expérimentation. Avec un entraînement sur l'intégralité des données, la littérature situe DistilBERT autour de 92 à 93 % sur IMDB, soit nettement devant nos modèles classiques. Ce prolongement constitue la suite naturelle du projet.

5. De l'expérimentation à l'application

Un modèle n'a d'intérêt que s'il est utilisable. Nous avons donc développé une application web où l'on saisit un texte et obtient immédiatement le sentiment prédit, accompagné d'un indice de confiance. Le modèle employé est sélectionnable, ce qui permet de comparer les approches en direct.

Application accessible en ligne : <https://sentimentai-df0c.onrender.com>

Choix techniques

L'application est écrite en Python avec le framework Flask. Elle expose également une interface de programmation permettant d'analyser un texte isolé ou une série de textes en une seule requête, ce qui est utile pour traiter un fichier d'avis.

Le service est mis en ligne automatiquement : chaque modification déposée sur le dépôt déclenche un nouveau déploiement. Seule la régression logistique y est embarquée, car sa taille réduite lui permet de fonctionner sur un hébergement gratuit. C'est une conséquence directe de l'analyse précédente : le modèle le plus léger se révèle aussi le plus performant et le seul déployable.

Qualité du code

Le projet comporte 91 tests automatiques vérifiant le nettoyage du texte, le comportement des modèles et les réponses de l'interface web. Ils sont exécutés automatiquement à chaque modification. Les tirages aléatoires sont fixés, si bien que deux entraînements identiques produisent exactement les mêmes résultats, condition indispensable à une comparaison honnête.

Les versions des bibliothèques sont également figées. Charger un modèle enregistré avec une version différente de scikit-learn peut en effet fausser silencieusement les prédictions : la reproductibilité ne s'arrête pas aux tirages aléatoires.

6. Conclusion

Ce projet a permis de construire une chaîne complète, du jeu de données brut jusqu'à une application en ligne. Le meilleur modèle, la régression logistique, atteint 89.2 % de bonnes réponses sur 25 000 critiques jamais vues pendant l'entraînement.

Son principal enseignement n'est pas un score, mais une nuance : la sophistication d'un modèle ne garantit pas sa supériorité. Les moyens disponibles, en données comme en calcul, pèsent autant que le choix de l'algorithme.

Perspectives

- Entraîner DistilBERT sur l'intégralité des données avec une carte graphique, pour vérifier l'écart attendu.

- Étendre l'analyse à d'autres langues, notamment le français.
- Dépasser la distinction positif/négatif en détectant des nuances comme l'ironie.